Autor: Pablo Jesús Delgado Muñoz

Práctica 1

1) Diferencias entre Data Poisoning y Adversarial Attacks

Los ataques de Data Poisoning se encuentran en una fase totalmente diferente a los adversarial attacks, los de data poisoning normalmente se encuentran en la parte de ingesta de datos, y todo su ciclo de vida, ya sea por técnicas como label flipping, inyección de muestras maliciosas o mucho más, se refiere principalmente a la parte de los datos, mientras que los adversarial attacks se encuentran enfocados en la parte de inferencia, donde se modifica el input para un objetivo en específico, no se modifica el modelo, sino la entrada. Normalmente la operaciÍon sería trata de modificar el input basándose en una función objetivo que diseñada por el atacante para obtener su objetivo deseado, moviendose en cierta dirección según el gradiente y con diferentes variaciones posibles de algoritmos, por ejemplo si hablamos de FGSM nos movemos únicamente en la dirección que devuelve nuestro gradiente de la función de coste diseñada basada en los parámetros del modelo (fijos), el input y la salida objetivo (que puede ser específica si queremos acercanos a un target, osea es targeted attack, o si no es targeted simplemente queremos bajar accuracy y nos movemos en direción contraria a la salida del modelo actual) moviendonos en el máxmimo paso posible que nos permite el presupuesto según la dirección que nos devuelve la funcion sign(gradiente). Y así modificando el input tipo: x_adv = x + perturbación. Esta perturbación funciona porque explota la naturaleza lineal de los modelos en problemas de alta dimensionalidad, al modificar todas las partes del input en la dirección de los pesos (sign(w)), el modelo suma todos estos pequeños cambios hasta provocar un crecimiento muy grande en la activación final, por lo tanto funciona gracias a la naturaleza lineal y la alta dimensionalidad, epsilon * m * n siendo m el tamaño medio de la matriz de pesos W y n el numero de características a modificar. Por eso podemos tener pequeñas variaciones casi inpercepcibles, porque al sumar todas estas pequeñas modificaciones en tantas dimensiones, se llega a un cambio en el output suficientemente grande para conseguir el objetivo deseado.

2) Ataques Globales (Perturbaciones) vs. Ataques Localizados (Parches)
El metodo clasico FGSM (Fast Gradient Sign Method) modifica sutilmente todos los píxeles de una imagen completa para enganar al modelo. Explica por que un ataque global como FGSM es tecnicamente imposible de replicar por un atacante en una senal de trafico real en mitad de una carretera, y por que la introduccion de "parches o mascaras" (patches) soluciono este problema para los atacantes.

Básicamente porque el algoritmo FGSM es de un único paso y modifica todos los píxeles de la imagen al mismo tiempo, el resultado normalmente suele ser ruido de alta frecuencia, cambios pequeños e impercetibles o poco visibles que no sobreviven transformaciones de adaptación al mundo real como impresión, por lo tanto crear un ejemplo adversarial mediante este algoritmo es realmente muy complicado. Se solucionó en gran parte simplificando el problema, es muy complejo en el mundo real modificar toda la escena que recibirá el modelo, es decir, si lo que hacemos es aplicar y crear una perturbacion en toda la escena, cómo vamos a modificar aquelloq ue está en el fondo, detrás de la señal de tráfico por ejemplo? No es posible. Es entonces cuando entran en uso estos parches, pequeñas regiones donde se puede aplicar esta perturbación y que concentran esta perturbación en un lugar más acotado, lo que lleva por ende a transformaciones que pueden ser más visibles y podrían llegar a sobrevivir las transformaciones hasta el mundo físico y la ingesta por parte del sensor hasta el modelo. Además estos ataques tienen que sobreviri las transformaciones al mundo real, y tienen que ser perceptibles con cierto mínimo.

3) El algoritmo RP2 (Robust Physical Perturbations)
En el mundo digital, cambiar un solo píxel de forma milimetrica puede enganar a una IA. Sin embargo, en el mundo físico, una pegatina en una senal recibe sombras, reflejos del sol y se ve desde multiples distancias mientras el coche se acerca. ¿Como consigue el algoritmo RP2 que los patrones de la pegatina sigan siendo efectivos a pesar de todas estas transformaciones visuales del entorno?
Realiza Expectation over transformations, lo que hacen es samplear diferentes transformaciones del mundo físico y digital en Xv, usan una mácara Mx para solo aplicar la perturbación a ese área y aplican otras formas de regualazion como NPS para cuando impriman las pegatinas. Todo esto junto queda en una fórmula que busca la perturbación optima que satisface todas las condiciones:

$$\begin{aligned} &\underset{\delta}{\operatorname{argmin}}\ \lambda||M_x \cdot \delta||_p + NPS \\ &+ \mathbb{E}_{x_i \sim X^V} J(f_\theta(x_i + T_i(M_x \cdot \delta)), y^*) \end{aligned} \tag{2}$$

4) Visibilidad Humana vs. Artificial
Para que un ataque adversario sea exitoso en un entorno real se busca que pase desapercibido por los humanos pero que confunda por completo a la maquina. Describe visualmente como percibe un conductor humano la senal de stop hackeada del artículo frente a como la procesa matematicamente la red neuronal del vehículo. ¿Por que este contraste asimetrico representa un peligro para la seguridad vial?
El ser humano está acostumbrado a ver señales sucias, con graffiti y diferentes variaciones, pero el modelo ha sido entrenado de forma normal con clean images sin estas transformaciones, el ser humano no ve “problema” pero el modelo si se ve afectado debido que se ha generado ese parche adversaial que es posible generar gracias a la naturaleza lineal de los modelos. Entonces como el ser humano no ve problema puede que queden en su sitio estas amenazas y que los modelos que conducen estos vehículos autónomos se vean afectados mientras que nadie le toma importancia.

5) Interpretacion de la Resistencia Ambiental
El artículo [P1b] concluye con la frase: "This implies that future defenses should not rely on physical sources of noise as protection against physical adversarial examples". Explica con tus propias palabras que crees que pensaban los ingenieros de software sobre el "ruido físico" (cambios de luz, distancia, angulos de la camara) antes de este estudio y por que los autores demostraron que esa confianza era un grave error de seguridad.
Básicamente que no deberían de confiar en las variaciones o ruido físico del mundo real como protección del modelo porque han demostrado que se puede optimizar sobre aproximaciones de estas transformaciones y obtener perturbaciones adversariales que realmente funcionan en situaciones reales debido a la naturaleza lineal de estos modelos.